

연구계획서

멀티모달 데이터 잠재 결합 기반 CNN-GRU-MLP 대리모델을 이용한 한국 연안 폭풍해일 잔차수위 예측

장민엽

1 연구 배경

태풍은 강풍, 저기압, 파랑을 동반하며 한국 연안의 해수위 상승과 storm surge를 일으킨다 (Park et al., 2022). 한국 주변의 얇은 연안해역은 조석, 동아시아 몬순, 계절 순환, 하천 유입, 늦여름 및 초가을의 태풍 활동이 함께 작용하는 복합 물리 환경이다 (Hwang et al., 2014). 따라서 연안 조위관측소에서 나타나는 해수위 반응은 태풍 중심의 경로와 강도만으로 결정되지 않는다. 관측소와 태풍의 거리, 접근 방향, 태풍 크기, 이동속도, forcing 지속시간이 함께 작용한다 (Lee et al., 2021).

기존 물리 기반 폭풍해일 모형은 연안 수리 현상을 직접 모의할 수 있고, 결과 해석이 비교적 명확하다는 장점이 있다. 그러나 실제 적용에는 고해상도 지형·수심 격자, 개방경계 조건, 조석 및 기상 외력, 저면마찰·난류 모수화, 관측자료 기반 검보정 과정이 필요하다. 태풍 경로와 강도 입력의 작은 오차도 연안 수위 예측으로 전파될 수 있으며, 여러 태풍과 관측소를 대상으로 반복 실험을 수행하면 계산비용과 전처리 부담이 커진다 (Bajo et al., 2017). 또한 regional ocean model의 one-way nesting 기반 동역학 다운스케일링은 격자 해상도 차이, 경계 갱신 주기, 도메인 크기, small-scale motion 재생성을 위한 spin-up 설정에 민감하므로, 반복적인 태풍-관측소 실험에서는 계산적·설정적 부담이 커질 수 있다 (Pham et al., 2016). 따라서 태풍 조건별 예측 경향을 빠르게 비교하려는 초기 연구에서는 물리 모형만으로 접근하기 어렵다.

이 한계를 극복하기 위해 최근 폭풍해일과 극단 해수위 연구에서는 재분석 자료, 관측자료, data-driven model, machine-learning surrogate를 활용하는 사례가 늘고 있다 (Qin et al., 2023). ML 및 deep learning 기반 모형은 수위와 기상·해양 외력 사이의 비선형 관계를 자료에서 직접 학습하므로, 복잡한 수치모형을 반복 구동하지 않고도 빠른 추론과 비교 실험을 수행할 수 있다 (Tadesse et al., 2020; Zafor & Rashid, 2026). 선행연구에서는 태풍 track 시계열을 이용한 peak storm surge 예측, 재분석 기반 2D 기상장 또는 gridded predictor를 활용한 storm-surge 예측, 관측소 또는 지역 특성 변수를 반영한 지역별 surge modeling이 각각 시도되었다 (Lee et al., 2021; Su et al., 2025; Zafor & Rashid, 2026).

그러나 이러한 연구들은 서로 다른 입력 자료를 활용했다는 점에서는 의미가 있지만, 입력 자료의 성격 차이를 모델 구조 안에서 어떻게 처리할 것인지에 대해서는 상대적으로 취약하다. ERA5 2D 기상·파랑장은 공간 구조를 갖는 격자 자료이고, 태풍 best-track은 시간 순서가 중요한 시계열 자료이며, 관측소 정보는 시간에 따라 변하지 않는 정적 자료이다 (Hersbach et al., 2020; Knapp et al., 2018). 서로 다른 modality의 입력은 각 입력의 표현을 먼저 학습한 뒤 결합할 때 상보적인 정보를 더 체계적으로 사용할 수 있다 (Baltrusaitis et al., 2019). 따라서 세 입력을 원자료나 단순 feature 단계에서 바로 합치기보다, 각 자료 구조에 맞는 encoder에서 먼저 해석한 뒤 latent representation 단계에서 concatenation하는 구조를 검토할 필요가 있다. 본 연구는 세 입력 자료를 각각 CNN-GRU, GRU, MLP encoder로 처리하고, 생성된

embedding을 latent representation 단계에서 결합하는 compact hindcast surrogate model을 구성한다. 사후 event 요약값은 모델 입력으로 사용하지 않는다. 이를 통해 2D field 입력과 station-aware feature가 branch-wise encoding 및 latent fusion 구조 안에서 예측 성능에 어떻게 기여하는지 평가하고, 연안 폭풍해일의 잔차수위를 예측한다.

2 연구 목적

본 연구의 목적은 한국 연안 조위관측소의 storm-surge residual을 예측하기 위해 과거 48시간 ERA5 해상 기상·파랑장, 태풍 best-track 시계열, 관측소 정적 정보를 결합한 station-aware CNN-GRU-MLP hindcast 모델을 설계하는 데 있다. 아울러 태풍의 크기와 이동속도에 따라 예측 오차가 어떻게 달라지는지 비교해, 단순한 평균 정확도 평가를 넘어 태풍 조건별 예측 난이도를 함께 분석한다.

핵심 연구 질문은 다음과 같다.

1. 과거 48시간 ERA5 2D field, 태풍 best-track 시계열, 관측소 정적 정보를 각각 다른 encoder로 처리한 뒤 latent representation 단계에서 concatenate하는 구조는 단순 feature 결합 방식보다 향후 24시간 storm-surge residual 예측 성능을 개선하는가?
2. ERA5 2D field 입력과 station-aware feature는 결합 모델의 예측 성능에 각각 어느 정도 기여하는가?
3. 결합 모델의 예측 오차는 태풍 크기 그룹과 이동속도 그룹에 따라 어떤 차이를 보이는가?

3 연구 범위

3.1 공간적 범위

본 연구는 초기 공간 범위를 우리나라 제주권, 남해안, 대한해협에 위치한 일부 조위관측소로 제한한다. 후보 관측소는 제주, 서귀포, 성산포, 완도, 거문도, 여수, 통영, 부산 등이다 (Korea Hydrographic and Oceanographic Agency, n.d.).

그림 1은 후보 조위관측소와 ERA5 2D field 고정 도메인을 함께 나타낸 것이다. 고정 도메인은 제주 남쪽 해역, 남해안, 대한해협, 일본 규슈 주변 해역을 포함하도록 설정해, 태풍 접근 경로와 관측소 위치를 같은 좌표계에서 다룰 수 있도록 한다.

3.2 시간적 범위

대상 태풍은 2010년 이후 우리나라 연안 수위에 영향을 준 사례 중 태풍 best-track 자료와 조위 관측자료를 함께 확보할 수 있는 경우로 선별한다 (Korea Hydrographic and Oceanographic Agency, n.d.; Knapp et al., 2018).

그림 1의 Route 1, Route 2, Route 3은 2010년 이후 IBTrACS best-track 자료 중 고정 도메인에 진입하고 후보 관측소 주변을 통과한 태풍 사례를 대표 접근 경로로 군집화한 결과이다. 이 경로 구분은 예측 대상 태풍을 단순히 전체 평균으로만 평가하지 않고, 접근 방향과 이동 경로에 따른 오차 차이를 함께 검토하기 위한 기준으로 활용한다.




그림 1: 2010년 이후 한국 연안 태풍 영향권, 후보 조위관측소 및 ERA5 2D field 고정 도메인

3.3 예측 대상

예측 대상은 storm-surge residual이며, 실측 조위에서 예측 천문조를 제거한 값으로 정의한다.

$$\eta_{\text{res}}(t) = \eta_{\text{obs}}(t) - \eta_{\text{tide}}(t) \quad (1)$$

여기서 $\eta_{\text{res}}(t)$ 는 storm-surge residual, $\eta_{\text{obs}}(t)$ 는 KHOA 실측 조위, $\eta_{\text{tide}}(t)$ 는 예측 천문조를 의미한다. 본 연구에서는 이 비천문조 성분을 모델의 목표 변수로 사용한다 (Park et al., 2022).

4 연구방법

4.1 입력 자료

4.1.1 ERA5 해상 기상·파랑장 입력

각 태풍 사례에 대해 우리나라 남해안, 제주권, 대한해협과 주변 해역을 포함하는 고정 ERA5 2D 도메인을 구성한다 (Hersbach et al., 2020). ERA5는 재분석자료이므로, 본 연구에서는 예측 기준시점까지의 과거 48시간을 입력으로 사용한다 (표1).

$$X_{\text{field}} \in \mathbb{R}^{T \times C \times H \times W} \quad (2)$$

초기 모델에서는 다음 변수를 입력으로 사용한다.

표 1: ERA5 해상 기상·파랑장 입력 변수

변수	의미
u10, v10	10 m 바람 성분
mslp	해면기압
swh	유의파고
station mask	예측 대상 관측소 위치
distance-to-station map	각 격자점과 관측소 사이 거리

고정 도메인을 사용하면 태풍 접근 경로, 관측소 위치, 주변 바람장·기압장·파랑장을 같은 좌표계에서 함께 학습할 수 있다.

4.1.2 태풍 동적 시계열 입력

태풍 사례별로 일정 시간 간격의 동적 시계열을 구성한다 (Knapp et al., 2018).

$$X_{\text{dyn}} \in \mathbb{R}^{T \times F_{\text{dyn}}} \quad (3)$$

주요 변수는 표2와 같다.

표 2: 태풍 동적 시계열 입력 변수

변수	의미
latitude, longitude	태풍 중심 위치
central pressure	중심기압
maximum wind speed	최대풍속
R15 or strong wind radius	강풍반경
moving speed	태풍 이동속도
distance to station	태풍 중심과 관측소 사이 거리
relative bearing	태풍 진행방향 대비 관측소 상대각

초기 설정에서는 예측 기준시점까지의 과거 48시간 태풍 시계열을 입력으로 사용한다. 태풍 경로 시계열을 순환 신경망 기반 시계열 모델과 결합하는 접근은 기존 storm-surge 및 water-level forecasting 연구와 연결된다 (Chen et al., 2022).

4.1.3 관측소 정적 입력 및 사후 그룹 변수

시간에 따라 변하지 않는 관측소 단위 입력 변수는 별도로 구성한다. 이 입력은 예측 대상 관측소의 위치와 노출 조건을 모델에 분리해 전달하기 위한 것이다. 태풍 event 전체가 끝난 뒤에야 계산되는 최소거리, 최대풍속, 최저기압, 평균 또는 최대 강풍반경 등은 모델 입력에서 제외하고, 평가 단계의 그룹 분석 변수로만

사용한다.

$$X_{\text{stat}} \in \mathbb{R}^{F_{\text{stat}}} \quad (4)$$

주요 변수는 표3과 같다.

표 3: 관측소 단위 정적 입력 변수

변수	의미
station latitude, longitude	관측소 위치
station ID or embedding	관측소 식별자
coast region	제주권 / 남해안 / 한국해협
coast-normal angle	해안선 법선 방향
station depth	관측소 주변 수심, 가능 시 사용

사후 event 요약값은 모델 입력이 아니라 평가 단계의 그룹 분석 변수로만 사용한다. 여기에는 해당 태풍과 관측소의 최소거리, 평균 또는 최대 R15, 평균 이동속도, event 최대풍속, event 최저 중심기압, size group, speed group이 포함된다.

4.2 모델 구조

초기 모델은 세 개의 인코더와 하나의 예측 head로 구성한다. ERA5 해상 기상·파랑장은 각 시각마다 2차원 격자 구조를 가지므로, 먼저 CNN encoder를 이용해 공간 패턴을 저차원 embedding으로 압축한다. 이후 GRU encoder가 시간 순서에 따른 forcing 변화와 storm-surge residual 반응을 학습하도록 구성한다. 태풍 동적 시계열 branch도 GRU 인코더를 사용하고, 정적 입력 branch와 fusion head는 MLP 구조로 둔다 (Cho et al., 2014).




그림 2: Station-aware CNN-GRU-MLP 모델 구조

세 branch의 결합은 원자료 단계가 아니라 각 인코더가 만든 잠재 표현 단계에서 수행한다.

$$h = [h_{\text{field}}; h_{\text{dyn}}; h_{\text{stat}}] \quad (5)$$

여기서 h_{field} 는 CNN-GRU가 ERA5 2D field sequence에서 추출한 embedding, h_{dyn} 은 GRU가 태풍 best-track 시계열에서 추출한 embedding, h_{stat} 은 MLP가 관측소 정적 입력에서 추출한 embedding이다. 결합된 벡터는 fusion MLP를 통과해 향후 24시간의 residual sequence를 출력한다.

5 학습 및 검증 방법

기본 손실함수는 peak-window weighted MSE로 설정한다. 이는 예측 residual sequence와 관측 residual sequence 사이의 전체 오차를 보되, 관측 peak가 발생한 시간 전후의 오차에 더 큰 가중치를 주는 방식이다. 초기 구현의 optimizer는 Adam을 사용한다 (Kingma & Ba, 2015).

$$L = \frac{\sum_{i=1}^{24} w_i (\hat{y}_i - y_i)^2}{\sum_{i=1}^{24} w_i} \quad (6)$$

여기서 t_{peak} 는 관측 residual sequence에서 peak가 발생한 시각이고, k 는 peak 주변 window 크기이다.

$$w_i = \begin{cases} 1 + \alpha, & |i - t_{\text{peak}}| \leq k \\ 1, & \text{otherwise} \end{cases} \quad (7)$$

초기 설정은 $k = 3$ hours, $\alpha = 2$ 로 두며, 단순한 $\max(\hat{Y}) - \max(Y)$ 기반 peak loss는 peak timing 불일치를 충분히 반영하지 못하므로 주 손실함수로 사용하지 않는다.

검증은 무작위 train-test split 대신 leave-one-typhoon-out validation으로 수행한다. 특정 태풍을 test event로 완전히 분리해, 학습에 사용하지 않은 태풍 사례에 대한 일반화 성능을 확인하기 위한 설정이다 (Tadesse et al., 2020).

- Train: 특정 태풍 1개를 제외한 나머지 태풍
- Test: 제외한 태풍 1개
- Repeat: 모든 태풍을 한 번씩 test event로 사용

이 방식은 새로운 태풍 사례에 대한 예측 가능성을 평가하는 데 적합하다.

5.1 평가 지표

전체 시계열 예측 성능은 평균 제곱근 편차(RMSE)와 평균 절대 오차(MAE)로 평가한다.

$$RMSE = \sqrt{\frac{1}{n} \sum_i (\hat{y}_i - y_i)^2} \quad (8)$$

$$MAE = \frac{1}{n} \sum_i |\hat{y}_i - y_i| \quad (9)$$

폭풍해일 예측에서는 평균 오차뿐 아니라 peak 관련 성능도 함께 평가한다 (표4). Peak magnitude와 timing은 operational forecasting에서 중요한 평가 관점이다 (Bajo et al., 2017).

표 4: Storm-surge residual 예측 평가 지표

지표	정의
Peak magnitude error	$\max(\hat{Y}) - \max(Y)$
Peak timing error	$t_{\max}(\hat{Y}) - t_{\max}(Y)$
Group-wise RMSE / MAE	태풍 크기·이동속도 그룹별 평균 오차

분석 결과는 small / medium / large 태풍과 slow / medium / fast 태풍 그룹으로 나누어 비교한다.

5.2 비교 실험

비교 실험은 2D field 입력의 기여도와 station-aware feature의 효과를 분리해 확인할 수 있도록 표5와 같이 구성한다.

표 5: 비교 실험 구성

구분	모델	목적
Baseline 1	Persistence model	현재 residual 유지 가정과 비교
Baseline 2	Random Forest or XGBoost	비딤러닝 기준모델 (Chen & Guestrin, 2016)
Deep model 1	GRU-MLP	best-track 및 정적 feature만 사용
Deep model 2	CNN-GRU-MLP	ERA5 2D field, best-track, 정적 feature 결합
Ablation	CNN-GRU without station-aware features	station-aware feature 기여도 확인

이 비교를 통해 단순 지속성 가정, 비딤러닝 기준모델, best-track 기반 GRU-MLP, 2D field 결합 CNN-GRU-MLP 사이의 성능 차이를 확인한다. 특히 ablation 실험은 관측소 위치와 노출 조건을 반영한 station-aware feature가 예측 성능에 기여하는지 평가하기 위한 것이다.

6 기대 효과

본 연구는 과거 48시간 ERA5 해상 기상·파랑장, 태풍 best-track 시계열, 관측소 정적 조건을 결합한 deep learning model이 한국 연안 storm-surge residual 예측에 활용될 수 있는지 평가한다 (Park et al., 2022). 평균 오차뿐 아니라 peak magnitude error, peak timing error, 태풍 크기·이동속도별 오차 패턴을 함께 분석하고, 어떤 태풍 조건에서 예측 난이도가 커지는지 평가한다 (Bajo et al., 2017).

이 연구는 향후 multi-station prediction, coastal metocean surrogate model, 해양 유동 초고속 예측으로 확장하기 위한 초기 모듈로 활용될 수 있다 (Kim & Hwang, 2025).

본 연구성과는 관련분야 최고 수준의 논문집에 2편이상 투고하며, 국내외 학술발표회(AGU)에 참석하여 연구내용을 발표하고 연구성과를 교류한다.

7 요약

본 연구는 한국 연안 조위관측소의 storm-surge residual을 예측하기 위해 과거 48시간 ERA5 해상 기상·파랑장, 태풍 best-track 시계열, 관측소 정적 조건을 결합한 station-aware CNN-GRU-MLP hindcast 모델을 설계한다. ERA5 2D field는 CNN-GRU branch로 처리해 공간 패턴과 시간 변화를 함께 학습하고, 태풍 best-track 시계열은 별도 GRU encoder로 처리한다. 관측소 위치, 해안권역, 해안선 방향, 수심 등 예측 시점 이전에 알 수 있는 정적 입력은 MLP encoder로 처리한 뒤 세 branch의 잠재 표현을 결합한다. 태풍-관측소 최소거리, 태풍 크기·이동속도 요약값, event 최대풍속과 최저기압 등 사후 event 요약값은 모델 입력에서 제외하고 평가 단계의 그룹 분석 변수로만 사용한다.

모델은 fusion MLP를 통해 향후 24시간의 storm-surge residual sequence를 예측한다. 학습 손실은 실제 peak 전후 시간 구간에 더 큰 가중치를 주는 peak-window weighted MSE를 사용한다. 성능 평가는 leave-one-typhoon-out validation으로 수행하며, 평균 제곱근 편차(RMSE), 평균 절대 오차(MAE), peak magnitude error, peak timing error를 함께 사용한다. 비교 실험에서는 persistence model, 비딥러닝 기준모델, GRU-MLP, CNN-GRU-MLP, station-aware feature 제거 모델을 비교해 2D field 입력과 station-aware feature의 기여도를 분리해 확인한다.

8 참고문헌

1. Bajo, M., De Biasio, F., Umgiesser, G., Vignudelli, S., & Zecchetto, S. (2017). Impact of using scatterometer and altimeter data on storm surge forecasting. *Ocean Modelling*, 113, 85–94. <https://doi.org/10.1016/j.ocemod.2017.03.014>
2. Baltrusaitis, T., Ahuja, C., & Morency, L.-P. (2019). Multimodal Machine Learning: A Survey and Taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2), 423–443. <https://doi.org/10.1109/TPAMI.2018.2798607>
3. Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD 2016*. <https://doi.org/10.1145/2939672.2939785>
4. Chen, X., et al. (2022). Storm Surge Prediction Based on Long Short-Term Memory Neural Network in the East China Sea. *Applied Sciences*, 12(1), 181. <https://www.mdpi.com/2076-3417/12/1/181>
5. Cho, K., et al. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. *EMNLP 2014*. <https://doi.org/10.3115/v1/D14-1179>
6. Hersbach, H., et al. (2020). The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146(730), 1999–2049. <https://doi.org/10.1002/qj.3803>
7. Hwang, J. H., Van, S. P., Choi, B.-J., Chang, Y. S., & Kim, Y. H. (2014). The physical processes in the Yellow Sea. *Ocean & Coastal Management*, 102, 449–457. <https://doi.org/10.1016/j.ocecoaman.2014.03.026>

8. Kim, B.-K., & Hwang, J. H. (2025). Fast oceanic flow prediction using lattice- and morphology-informed approaches. *Physics of Fluids*. <https://doi.org/10.1063/5.0255741>
9. Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. *International Conference on Learning Representations*. <https://doi.org/10.48550/arXiv.1412.6980>
10. Knapp, K. R., Diamond, H. J., Kossin, J. P., Kruk, M. C., & Schreck, C. J. (2018). International Best Track Archive for Climate Stewardship (IBTrACS) Project, Version 4. NOAA National Centers for Environmental Information. <https://doi.org/10.25921/82ty-9e16>
11. Korea Hydrographic and Oceanographic Agency. (n.d.). Tide and tidal current observation data. <https://www.khoa.go.kr/>
12. Lee, J., et al. (2021). Rapid prediction of peak storm surge from tropical cyclone track time series using machine learning. *Coastal Engineering*. <https://repository.library.noaa.gov/view/noaa/57525>
13. Park, K., et al. (2022). Storm Surge Forecasting along Korea Strait Using Artificial Neural Network. *Journal of Marine Science and Engineering*, 10(4), 535. <https://www.mdpi.com/2077-1312/10/4/535>
14. Pham, V. S., Hwang, J. H., & Ku, H. (2016). Optimizing dynamic downscaling in one-way nesting using a regional ocean model. *Ocean Modelling*, 106, 104–120. <https://doi.org/10.1016/j.ocemod.2016.09.009>
15. Qin, Y., Su, C., Chu, D., Zhang, J., & Song, J. (2023). A Review of Application of Machine Learning in Storm Surge Problems. *Journal of Marine Science and Engineering*, 11(9), 1729. <https://doi.org/10.3390/jmse11091729>
16. Su, C., Sahoo, B., Mao, M., & Xia, M. (2025). Machine learning techniques for predicting typhoon-induced storm surge using a hybrid wind field. *Journal of Geophysical Research: Machine Learning and Computation*. <https://doi.org/10.1029/2024JH000507>
17. Tadesse, M. G., Wahl, T., & Cid, A. (2020). Data-driven modeling of global storm surges. *Frontiers in Marine Science*, 7, 260. <https://doi.org/10.3389/fmars.2020.00260>
18. Zafor, M. A., & Rashid, M. M. (2026). Large-Scale Deep Learning-Based Hourly Storm Surge Modeling: Application Across the U.S. Gulf and East Coasts. *Earth Systems and Environment*. <https://doi.org/10.1007/s41748-026-01039-0>